

1. Está trabajando en un algoritmo ML de clasificación binaria que detecta si un paciente tiene una enfermedad específica. En su conjunto de datos, el 98 % de los ejemplos de capacitación (pacientes) no tienen la enfermedad, por lo que el conjunto de datos está muy sesgado. La precisión en las clases tanto positivas como negativas es importante. Usted lee un artículo de investigación que afirma haber desarrollado un sistema que alcanza el 95 % en la métrica \_\_\_\_\_. ¿Qué métrica le daría la mayor confianza de que han creado un sistema útil y no trivial? (Seleccione uno)

1 / 1 punto

☐ Recuerdo

☒ Puntuación F1

☐ Precisión

☐ Precisión

☒ **Correcto**

¡Así es! La puntuación F1 se recomienda en conjuntos de datos sesgados, ya que combina precisión y recuperación en una sola métrica.

2. En el problema anterior con 98% de ejemplos negativos, si su algoritmo está impreso ("1") (es decir, dice que todos tienen la enfermedad). Cual de esas declaraciones es cierta?

1 / 1 punto

☒ El algoritmo logra un 100% de recuperación.

☐ El algoritmo alcanza el 100% de precisión.

☐ El algoritmo logra una precisión del 0%.

☐ El algoritmo logra un 0% de recuperación.

☒ **Correcto**

Así es, ya que clasificaría a todos como portadores de la enfermedad y por lo tanto sin falsos negativos. Recuerde, recordar es el número de *Verdaderos Positivos* / (*Verdaderos Positivos* + *Falsos Negativos*).

3. ¿Verdadero o falso? Durante el análisis de errores, a cada ejemplo solo se le debe asignar una etiqueta. Por ejemplo, en una aplicación de reconocimiento

1 / 1 punto

de voz, puede tener las etiquetas: "ruido de automóvil", "ruido de personas" y "bajo ancho de banda". Si encuentra un ejemplo con ruido de automóvil y audio de bajo ancho de banda, debe usar su juicio para asignar solo una de estas dos etiquetas en lugar de aplicar ambas etiquetas.

☐ Verdadero

☒ Falso

✓ **Correcto**

¡Así es! Cada ejemplo debe tener tantas etiquetas como sea necesario para clasificarlo con precisión. Esto lo ayudará a desarrollar una comprensión precisa de dónde provienen sus errores, lo que a su vez lo ayudará a concentrar sus esfuerzos en reducir los errores.

4. Está construyendo un sistema de inspección visual. El análisis de errores encuentra:

1 / 1 punto

tipo de defecto	Precisión	HLP	% de datos
Rascar	95%	98%	50%
Descoloramiento	90%	90%	50%

En base a esto, ¿cuál es el tipo de defecto más prometedor para trabajar?

☐ Decoloración, porque la precisión del algoritmo es menor y, por lo tanto, hay más margen de mejora.

☐ Decoloración, porque HLP es más bajo, lo que sugiere que este es el problema más difícil que necesita más atención.

☒ Defectos de scratch, porque la brecha con HLP es mayor y, por lo tanto, hay más margen de mejora.

☐ Trabaje en ambas clases por igual porque cada una es el 50% de los datos.

✓ **Correcto**

¡Así es! Todavía hay margen de mejora para su algoritmo.

5. Está considerando aplicar el aumento de datos a un problema de inspección visual del teléfono. ¿Cuáles de las siguientes afirmaciones son verdaderas

1 / 1 punto

sobre el aumento de datos? (Seleccione todas las que correspondan)

☒ Las GAN se pueden utilizar para el aumento de datos.

☒ **Correcto**

¡Así es! Las GAN son una forma de generar más imágenes y aumentar el tamaño de su conjunto de datos.

☒ El aumento de datos debe tratar de generar más ejemplos en las partes del espacio de entrada donde le gustaría ver una mejora en el rendimiento del algoritmo.

☒ **Correcto**

¡Así es! ¡El aumento de datos es una forma muy barata y fácil de aumentar el tamaño de su conjunto de datos!

☐ El aumento de datos debería tratar de generar más ejemplos en las partes del espacio de entrada donde el algoritmo ya funciona bien y no hay necesidad de mejorar.

☐ El aumento de datos debe distorsionar la entrada lo suficiente como para asegurarse de que también sean difíciles de clasificar para los humanos.